TECH CHALLENGE — FASE 4: DOCUMENTAÇÃO TÉCNICA E CIENTÍFICA

Integrantes do Grupo:
• Reinaldo Fernandes
• Leonardo González
• Caio Rubino

Programa: FIAP Pós-Tech — AI Scientist
Projeto: Olist Voice of Customer (VoC) Intelligence — Pipeline RAG Híbrido com Blindagem Anti-Alucinação e Auditoria Factual
Repositório Oficial: https://github.com/ReinaldoFernandes2013/tech-challenge-fase4-grupo
Vídeo Demonstrativo: https://youtu.be/dBbINnohcb8

1. Contexto de Negócio e Formulação Científica do Problema

No ecossistema de comércio eletrônico da Olist, dezenas de milhares de avaliações não estruturadas de clientes são registradas de forma contínua. Para as equipes de operações e logística, extrair manualmente as causas-raiz de falhas de transporte, atrasos na entrega e problemas com o serviço de atendimento ao cliente (SAC) é operacionalmente inviável devido à escala massiva de dados.

A adoção de soluções convencionais de Large Language Models (LLMs) via chatbots genéricos apresenta um risco inaceitável para tomadores de decisão executivos: a alucinação de fatos e a ausência de rastreabilidade factual.

O objetivo científico deste projeto foi conceber, calibrar e implementar uma plataforma de RAG Híbrido (Retrieval-Augmented Generation) de nível de produção (State of the Art — SOTA), governada por contratos rígidos de dados, dotada de um limiar empírico de abstenção segura (Fallback Graceful) e apoiada em auditoria de evidências ponto a ponto ancoradas no identificador real review_id.

2. Engenharia de Recuperação: Arquitetura RAG Híbrida de Dois Estágios

Para superar as limitações intrínsecas da recuperação puramente semântica (vetorial densa) — que habitualmente apresenta falhas na identificação de termos operacionais estritos —, desenhou-se um pipeline de dois níveis:

Nível 1: Motores Complementares de Recuperação

• Recuperação Léxica Esparsa (BM25): Indexação probabilística baseada em termos exatos do comércio eletrônico brasileiro, essencial para capturar códigos de produto, siglas de unidades federativas (UF), transportadoras e termos técnicos de reclamação.
• Recuperação Densa por Similaridade Semântica (ChromaDB): Geração de representações vetoriais (embeddings com MiniLM) para captura do contexto semântico, tom de frustração e sentimentos subjacentes dos clientes.

Nível 2: Fusão Algorítmica e Re-ranqueamento Neural

• Reciprocal Rank Fusion (RRF): Algoritmo determinístico com constante de suavização k = 60, responsável por fundir as listas de classificação do BM25 e do ChromaDB em uma ordenação agnóstica de escala:

$$RRF_Score(d \in D) = \sum_{m \in M} [\ 1 / (k + r_m(d))\ ]$$

• Cross-Encoder Neural (FlashRank): Mecanismo de atenção cruzada profunda par a par (pergunta × documento). Diferente de bi-encoders que comparam vetores isolados, o modelo processa as interações atencionais completas, calcula um score calibrado de pertinência, elimina falsos positivos e descarta contextos irrelevantes antes do envio ao modelo generativo, maximizando a métrica de Context Precision e reduzindo o consumo de tokens em 50%.

3. Governança Anti-Alucinação e Calibração Empírica de Threshold

Para cumprir as diretrizes formais da Tríade de RAG (Context Relevance, Groundedness e Answer Relevance) e garantir que o modelo nunca alucine perante cenários não mapeados, estabeleceu-se um procedimento formal de calibração empírica.

Através do script dedicado scripts/calibrate_threshold.py e do arquivo versionado de teste data/calibration_questions.json, submeteram-se consultas sob três domínios controlados:

Categoria da Consulta	Exemplos de Teste	Score Médio FlashRank	Comportamento do Sistema
In-Domain (Logística Olist)	"Atraso na entrega em SP", "Produto danificado"	≥ 0.6500	Execução nominal com citação de review_id
Edge-Cases (Fronteira Operacional)	"Qual o telefone do SAC da Olist?"	0.1500 - 0.3500	Recuperação parcial condicionada a contexto
Out-of-Domain (Fora do Domínio)	"Receita de bolo de cenoura", "Resultado do futebol"	< 0.1000	Bloqueio imediato via Fallback Gracioso

Limiar Crítico (Threshold = 0.1000): Consultas com pontuação de relevância estrita inferior a 0.1000 são interceptadas de forma determinística antes de consumirem recursos do LLM. O sistema emite uma resposta padronizada de abstenção segura ("Evidências insuficientes na base para sustentar uma análise factual"), atingindo uma latência de processamento de apenas 0.11 segundos.

4. Contratos de Dados Rígidos e Tipagem Estruturada (Pydantic V2)

A camada de geração não devolve texto livre ou não estruturado. Todas as saídas são forçadas contra um contrato de validação rigoroso implementado em Pydantic:

• InsightResponse: Modelo contendo o diagnóstico de risco, a estimativa inferida de CSAT, as causas-raiz categorizadas e a lista auditável de citações.

• CitationEvidence: Objeto estruturado obrigatório contendo review_id e o score de relevância. Qualquer afirmação devolvida pelo modelo generativo (Gemini 1.5 Flash) está vinculada a um registro factual persistido na base de dados. Violações de integridade ou scores inconsistentes são rejeitados em tempo de execução via validações automáticas do schema.

5. Qualidade de Software, MLOps e Testes Automatizados (Pytest)

A estabilidade operacional, a resiliência a falhas e a conformidade de engenharia foram validadas através de uma suíte extensiva de testes automatizados:

37 Testes Unitários e de Integração (37 passed — 100% de aprovação):
• tests/test_preprocessor.py: Validação de limpeza, tratamento de stop words e sanitização de texto em PT-BR.
• tests/test_retriever.py: Testes com mocks do motor híbrido (BM25 + ChromaDB) e ordenação via RRF.
• tests/test_rag_pipeline.py: Validação de acionamento do threshold e garantia de fallback sob perguntas out-of-domain.
• tests/test_router.py: Verificação de encaminhamento das intenções e regras de negócio.
• tests/test_schemas.py: Validação de restrições de tipos, contratos e validações de limites nos esquemas Pydantic.
• tests/test_api.py: Testes de integração das rotas do FastAPI (Health Check, validação de payload e execução simulada).

A utilização de Mocks garante a reprodutibilidade dos testes em esteiras de integração contínua (CI/CD) de forma independente de rede externa e sem consumo de custos de API.

6. Interface de Suporte à Decisão: Cockpit Executivo em Streamlit

O ecossistema disponibiliza um painel corporativo desenvolvido em Streamlit, conectado à API REST em FastAPI:

• Cockpit Executivo: Apresenta visualizações agregadas de sentimento, velocímetro de criticidade operacional e indicadores calculados de CSAT.
• Rastreabilidade Factual em Tempo Real: Mapeamento visual das causas-raiz apontadas pelo LLM diretamente associadas aos cartões de evidência com os seus respectivos review_id e metadados.
• Resiliência Visual: Em casos de perguntas fora de escopo, a interface exibe o alerta de segurança de evidência insuficiente, demonstrando visualmente o sucesso da calibração anti-alucinação.